

StudentsCompass como projeto de Data Analytics

Contexto, o que já temos, o que falta e o plano de trabalho para os próximos 6 meses

Análise de lacunas de habilidades e otimização de trilhas de aprendizagem para estudantes internacionais no Canadá, usando dados do mercado de trabalho, Machine Learning e otimização matemática (OR-Tools).

Conteúdo

1. Resumo em um minuto
2. O problema que resolvemos
3. O app é a demo, não o projeto
4. Como funciona, passo a passo
5. O que já temos
6. O que falta
7. O fio condutor: como tudo se conecta
8. Plano de 6 meses
9. Entregas: relatório, apresentação e pôster
10. Riscos e como lidamos com eles
11. Frentes de trabalho e próximos passos

1 Resumo em um minuto

A IDEIA EM UMA FRASE

Dado o currículo de um estudante, um cargo-alvo e um orçamento limitado de tempo e dinheiro, quais cursos ele deveria fazer para ficar o mais preparado possível para o mercado de trabalho real?

- **O que é:** nosso capstone do mestrado em Data Analytics. Combina análise de dados do mercado de trabalho, Machine Learning e otimização matemática.
- **O que é o StudentsCompass:** uma plataforma web que já existe e funciona. Para o capstone, ela é **a demo**, o lugar onde os resultados aparecem. **Não é o projeto.**
- **O projeto de verdade** é o motor analítico por trás: dados → extração de habilidades → medição de lacunas → modelos de ML → otimização → avaliação com métricas.
- **Já temos** uma parte importante: o enquadramento acadêmico, um dicionário de 117 habilidades, a extração automática de habilidades dos currículos, o cálculo de lacunas, um otimizador matemático com OR-Tools e sua comparação com 5 métodos simples.
- **Falta** principalmente: dados reais de vagas (hoje não temos nenhuma), a análise exploratória e estatística, modelos de ML treinados e avaliados, um catálogo de cursos realista, o dashboard e as três entregas.
- **Prazo:** 6 meses. **Entregas:** relatório escrito, apresentação oral e pôster de congresso (formato grande). Power BI é um diferencial, não um requisito.

Como o projeto cobre cada requisito do mestrado

Requisito	Como cobrimos	Status
Análise de dados	Quais habilidades o mercado canadense pede, por cargo, província e salário. Regressão salarial: quanto "vale" cada habilidade.	A fazer
Machine Learning	(1) Classificar currículos por área profissional. (2) Estimar o valor de mercado de cada habilidade. (Opcional) Agrupar vagas em perfis de cargo.	A fazer
Otimização	Modelo matemático (OR-Tools CP-SAT) que escolhe a melhor trilha de cursos respeitando orçamento, horas e outras restrições.	Feito Melhorar
Avaliação	O otimizador é comparado com métodos simples (o curso mais barato, o mais bem avaliado, um aleatório...) sob as mesmas restrições.	Feito Com dados reais
Visualização / BI	Dashboard (Power BI, se possível) e gráficos para o relatório e o pôster.	A fazer

2 O problema que resolvemos

Estudantes internacionais que querem começar ou crescer na carreira no Canadá enfrentam uma **lacuna** entre as habilidades que já têm e as que as vagas reais exigem. Existem milhares de cursos, certificações e recursos, mas não fica claro:

- quais habilidades realmente faltam para o cargo que querem;
- quais dessas habilidades mais importam no mercado;
- qual **combinação** de cursos fecha melhor essas lacunas, com o tempo e o dinheiro que eles têm.

O resultado é que muitos estudantes fazem cursos aleatórios ou se candidatam a tudo sem estratégia.

PERGUNTA DE PESQUISA

Dados um currículo, um cargo-alvo e restrições reais de tempo, custo e dificuldade, qual é a trilha ótima de cursos ou recursos que maximiza a cobertura de habilidades exigidas pelo mercado e melhora a preparação do estudante?

Objetivo geral

Projetar e implementar um sistema analítico que identifique as lacunas de habilidades entre estudantes internacionais e cargos-alvo, e que recomende trilhas de aprendizagem eficientes usando dados do mercado de trabalho, informações do currículo, Machine Learning e otimização.

Objetivos específicos

1. Construir uma base de dados analítica com habilidades, vagas, currículos, cursos e suas relações.
2. Extrair e normalizar habilidades de vagas e currículos, e **medir a precisão** dessa extração.
3. Analisar a demanda por habilidades no mercado canadense (análise exploratória e estatística).
4. Treinar e avaliar modelos de ML que classifiquem currículos e estimem o valor de mercado de cada habilidade.
5. Otimizar trilhas de aprendizagem sob restrições de orçamento, tempo, número de cursos e dificuldade.
6. Demonstrar com métricas que a trilha otimizada supera métodos simples de seleção.

Escopo

Para que o projeto seja defensável em 6 meses, nos concentramos em **3 cargos-alvo: Data Analyst, Business Analyst e Junior Data Scientist**. Se houver tempo, ampliamos para outros cargos no final.

3 O app é a demo, não o projeto

StudentsCompass é uma plataforma web de orientação profissional para estudantes no Canadá. Ela guia o estudante em etapas (autoconhecimento, currículo, LinkedIn, busca de emprego...) e tem uma seção chamada **Career Lab**, onde o estudante envia o currículo, escolhe um cargo-alvo e vê suas lacunas e uma trilha de cursos recomendada. Foi construída com FastAPI, PostgreSQL e React, e está publicada no Google Cloud.

O app existe e funciona, mas **não é o que a banca avalia**. Em um mestrado de Data Analytics somos avaliados pelos dados, pelos métodos, pelos resultados e por como os comunicamos. O app é a vitrine: serve para mostrar em 2–3 minutos que o sistema funciona com um caso real.

O projeto (o que é avaliado)

- Coleta e limpeza de dados do mercado de trabalho
- Extração e normalização de habilidades, com precisão medida
- Análise exploratória e estatística
- Modelos de Machine Learning treinados e avaliados
- Modelo de otimização e sua formulação matemática
- Avaliação contra métodos simples
- Dashboard, relatório, apresentação e pôster

A vitrine (o app StudentsCompass)


- Mostra o resultado para um usuário real
- Demo de 2–3 minutos no fim da apresentação
- QR code no pôster para testar
- Anexo no relatório

O QUE NÃO FAZ PARTE DO CAPSTONE

- A arquitetura do app, o frontend, o deploy na nuvem e o trabalho de engenharia de software.
- As funções de IA generativa do produto (chamadas ao Gemini para analisar currículos ou vagas).
Chamar um modelo de linguagem não conta como Machine Learning próprio: a banca espera modelos que nós mesmos treinemos, avaliemos e expliquemos.
- Novas funcionalidades do app. Durante estes 6 meses o app fica congelado e só mexemos no necessário para a demo.

4 Como funciona, passo a passo

O sistema é uma cadeia de seis passos. Cada passo usa o resultado do anterior.



■ já existe (precisa ser alimentado com dados reais) ■ novo

1 Coletar os dados

Três fontes: **vagas** (o que o mercado pede), **currículos** (o que os estudantes têm) e um **catálogo de cursos** com preço, duração, dificuldade e as habilidades que cada um ensina.

2 Extrair as habilidades

O sistema lê o texto de uma vaga ou de um currículo e detecta quais habilidades aparecem, usando um dicionário de 117 habilidades com seus sinônimos. Por exemplo, "Python 3" e "python programming" contam como a mesma habilidade: `python`. O estudante pode confirmar ou rejeitar o que foi detectado.

3 Medir a lacuna

O currículo é comparado com o que o cargo exige. Cada habilidade que falta recebe uma **pontuação de lacuna** que combina sua importância para o cargo, sua demanda no mercado e qualquer evidência parcial que o estudante já tenha. Assim, nem todas as lacunas pesam igual.

4 Estimar o valor de cada habilidade (ML, novo)

Um modelo de Machine Learning treinado com vagas reais estima quanto cada habilidade contribui para o salário ou para a empregabilidade. Hoje esses pesos são definidos à mão com uma fórmula; com o ML, eles vêm dos dados.

5 Otimizar a trilha de aprendizagem

Um modelo matemático (OR-Tools CP-SAT) escolhe a combinação de cursos que fecha as lacunas **mais valiosas** respeitando orçamento, horas disponíveis, número máximo de cursos, pré-requisitos e progressão de dificuldade, e evitando cursos redundantes.

6 Avaliar

Sob as mesmas restrições, a trilha otimizada é comparada com 5 métodos simples: o curso mais barato, o mais bem avaliado, o mais parecido por similaridade, a heurística anterior e uma seleção aleatória. São medidas 14 métricas: cobertura ponderada, cobertura de habilidades críticas, custo, horas, redundância etc.

Exemplo ilustrativo

CASO SIMPLIFICADO, SÓ PARA ENTENDER A LÓGICA

Perfil: estudante internacional em Toronto que quer ser **Data Analyst**. Tem 30 horas disponíveis e pode fazer no máximo 2 cursos.

Passo 2 — o que o sistema detecta no currículo: Excel e comunicação.

Passo 3 — o que falta (importância no cargo entre parênteses): SQL (0,95), limpeza de dados (0,90), visualização (0,90), Python (0,80), estatística (0,80), Power BI (0,75) e design de KPIs (0,70).

Passo 5 — o que o otimizador faz:

Opção	Horas	Cobre	Resultado
SQL for Data Analysis + Tableau Training	12 + 16 = 28	SQL, limpeza, visualização	Escolhida cobre as 3 lacunas mais valiosas
SQL for Data Analysis + Data Cleaning with Pandas	12 + 8 = 20	SQL, limpeza, Python	Válida, mas Python (0,80) vale menos que visualização (0,90)
SQL for Data Analysis + Power BI Data Analyst	12 + 22 = 34	SQL, limpeza, visualização, Power BI	Descartada passa de 30 horas
Python for Everybody	40	Python	Descartada passa de 30 horas

O otimizador real também exige uma cobertura mínima por habilidade (0,85 para as críticas e 0,70 para as demais) e penaliza custo, tempo e redundância. Por isso, o resultado real pode ser diferente deste exemplo.

Glossário rápido

Termo	O que significa aqui
Skill gap (lacuna)	Habilidade que o cargo exige e que o currículo não demonstra.
Normalização / taxonomia	Unificar nomes diferentes da mesma habilidade sob um nome padrão. ESCO é uma taxonomia pública europeia de habilidades e ocupações que podemos usar como referência.
Embeddings	Representar um texto como um vetor numérico para medir semelhança semântica ("análise de dados" se parece com "data analytics"). Usamos o modelo MiniLM armazenado no PostgreSQL com pgvector.
OR-Tools / CP-SAT	Biblioteca do Google de pesquisa operacional. CP-SAT é o seu solver: encontra a melhor combinação possível dentro de um conjunto de restrições.
Baseline	Método simples de referência. Se o otimizador não ganha dos baselines, ele não agrega valor.
EDA	Análise exploratória de dados: distribuições, tendências, correlações.
SHAP	Técnica para explicar um modelo de ML: quanto cada variável (no nosso caso, cada habilidade) contribui para uma previsão.
Precisão / recall	Precisão: do que detectamos, quanto está correto. Recall: do que existia, quanto detectamos.

5 O que já temos

O trabalho anterior foi feito em fases, documentadas em `docs/capstone_product/` e em `docs/capstone_phase_1_academic_plan.md` dentro do repositório.

Componente	Status	Detalhe
Enquadramento acadêmico	Feito	Título, pergunta de pesquisa, objetivos, escopo, métricas e pipeline conceitual.
Base de dados analítica	Feito	Tabelas de habilidades, sinônimos, currículos, vagas, cursos e execuções do otimizador.
Dicionário de habilidades	Feito	117 habilidades com sinônimos. 3 cargos-alvo com 9–10 habilidades exigidas cada, com sua importância.
Extração de habilidades	Feito	Baseada em regras e no dicionário. Aplicada a 2.484 currículos: pelo menos uma habilidade foi detectada em 98,4 % deles. <i>Isso mede cobertura, não precisão: ainda não sabemos quantas detecções estão corretas.</i>
Revisão pelo estudante	Feito	Confirmar, rejeitar ou adicionar habilidades antes da análise.
Pontuação de lacuna	Feito	Ordena as lacunas por importância × demanda do mercado, menos a evidência parcial.
Otimizador matemático	Feito	OR-Tools CP-SAT com restrições de orçamento, horas, número de cursos, cobertura mínima, dificuldade, pré-requisitos e redundância. Validado com casos sintéticos controlados.
Avaliação contra baselines	Feito	5 métodos de referência, 14 métricas e uma matriz de 5 cenários já desenhada. Falta rodá-la com dados reais.
Embeddings semânticos	Parcial	Implementados (MiniLM + pgvector), mas desligados por padrão: hoje é usado um vetor de preenchimento.
App de demo (Career Lab)	Feito	Em produção: currículo → cargo → lacunas e trilha.

Dados disponíveis hoje

Fonte	Volume	Comentário
Currículos rotulados (Kaggle Resume Dataset)	2.484	24 áreas profissionais (TI, finanças, saúde, vendas...). Base ideal para o modelo de classificação.
Currículos em Word (.docx)	228	Perfis de Business Analyst, Project Manager e Java. Têm nomes reais: precisam ser anonimizados.
Currículos em PDF por área	~8.900	Conjunto extra ou de teste (2,4 GB).
Vagas de emprego	0	O arquivo local de vagas está vazio. É o principal bloqueio.
Catálogo de cursos	12	Coursera, Kaggle, Microsoft Learn etc. Todos com custo zero , então hoje a restrição de orçamento não filtra nada.

6 O que falta

Em ordem de prioridade. Os dois primeiros itens bloqueiam todo o resto.

6.1 · DADOS DE VAGAS — BLOQUEANTE

Por que importa: sem vagas não há análise do mercado de trabalho, nem ML de valor das habilidades, nem lacunas baseadas em dados reais.

Como: usar datasets públicos em vez de scraping.

- **Job Bank Canada** (portal de dados abertos do Governo do Canadá, open.canada.ca): vagas canadenses com ocupação, localização e salário. É a opção que melhor combina com o foco no Canadá.
- **Statistics Canada:** vagas e salários por ocupação e província. Serve para completar salários ausentes.
- Alternativa: dataset do Kaggle "LinkedIn Job Postings" (grande, com habilidades e salários, mas majoritariamente dos EUA).

Primeira tarefa: baixar e verificar quais campos eles realmente trazem, principalmente o salário.

6.2 · AMOSTRA ROTULADA À MÃO — BLOQUEANTE PARA AS MÉTRICAS

Por que importa: hoje sabemos em quantos currículos detectamos habilidades, mas não se foram detectadas corretamente. Sem uma referência manual não podemos reportar precisão nem recall, e a banca vai perguntar.

Como: rotular à mão cerca de 100 vagas e 50 currículos (quais habilidades eles realmente contêm), com um guia de rotulagem comum. Se duas pessoas rotularem uma parte, também podemos medir a concordância entre elas.

6.3 · Análise exploratória e estatística

- Habilidades mais demandadas por cargo e por província.
- Habilidades que aparecem juntas (coocorrência) e como agrupá-las.
- Distribuição de salários e **regressão salarial**: quanto o salário aumenta com SQL, Python, Power BI...
- Comparação agregada entre os currículos e o mercado: onde estão as lacunas mais comuns.

6.4 · Machine Learning

Modelo	O que faz	Como é avaliado
1. Classificação de currículos	Prevê a área profissional de um currículo (24 categorias). Comparamos um modelo clássico (TF-IDF + regressão logística) com embeddings + classificador. Usa dados que já temos.	F1 macro, matriz de confusão, validação cruzada.
2. Valor de cada habilidade	Prevê o salário (ou a demanda) de uma vaga a partir das suas habilidades e, com SHAP, mede quanto cada uma contribui. É o modelo que se conecta com a otimização.	RMSE/MAE versus um modelo base; estabilidade da importância de cada habilidade.

Modelo	O que faz	Como é avaliado
3. Clustering (opcional)	Agrupar vagas em perfis de cargo descobertos a partir dos dados, em vez de defini-los à mão.	Silhouette, interpretação dos grupos.

6.5 · Otimização: melhorar o que já existe

- **Conectar o ML ao otimizador.** O modelo matemático já tem um parâmetro para o valor salarial de cada habilidade, mas hoje ele vale 0 por falta de dados. O Modelo 2 vai alimentá-lo.
- **Catálogo de cursos realista:** passar de 12 cursos gratuitos para mais de 100, com preço, horas e dificuldade reais (incluindo certificações pagas). Sem isso, o orçamento não restringe nada.
- **Análise de sensibilidade:** como a cobertura muda ao variar o orçamento e as horas. A curva resultante é um gráfico muito forte para o pôster.
- **Rodar a matriz de cenários** já desenhada (pouco orçamento, pouco tempo, equilibrado, outro cargo, restrições duras) com dados reais e reportar as tabelas.

6.6 · Visualização e dashboard

Um dashboard de 4 páginas: **Mercado de trabalho**, **Perfil dos currículos**, **Lacunas** (mapa de calor cargo × habilidade) e **Otimização** (comparação com os baselines e a curva de sensibilidade).

- **Power BI** é um diferencial. Atenção: o Power BI Desktop só funciona no Windows. Alternativas que funcionam no Mac: Looker Studio ou Tableau Public.
- O dashboard é alimentado por **tabelas limpas exportadas** (modelo estrela em CSV ou Parquet), nunca pelo banco de dados de produção do app.
- Os gráficos do relatório e do pôster são feitos em Python de qualquer forma.

7 O fio condutor: como tudo se conecta

Um erro comum em capstones é apresentar três peças soltas: "fizemos uma EDA, treinamos um modelo e também fizemos uma otimização". Neste projeto, cada peça alimenta a seguinte, e essa é a história que contamos:

Análise de dados

O que o mercado canadense pede e quanto paga por isso

Machine Learning

Transforma essa evidência em um valor numérico por habilidade

Otimização

Escolhe os cursos que maximizam esse valor com o tempo e o dinheiro disponíveis

Avaliação

Demonstra que ganha dos métodos simples

A FRASE PARA A BANCA

"A análise de dados nos diz o que o mercado pede; o Machine Learning nos diz quanto vale cada habilidade; a otimização decide o que cada estudante deve estudar para obter o máximo valor com seu tempo e seu dinheiro; e a avaliação demonstra que isso funciona melhor que as alternativas simples."

8 Plano de 6 meses

Regra principal: cada mês termina com uma análise pronta e o rascunho do capítulo correspondente do relatório. No último mês só polimos; não começamos a escrever.

Mês	Trabalho	Resultado para o relatório
1 • Outubro Dados e escopo	Validar a proposta com o orientador. Obter e revisar o dataset de vagas. Escolher a taxonomia (ESCO). Definir o guia de rotulagem e rotular a amostra manual. Começar a revisão de literatura.	Rascunhos de Introdução e Dados
2 • Novembro Análise de dados	Limpar e normalizar as habilidades. Medir a precisão e o recall do extrator contra a amostra. EDA completa e regressão salarial.	Capítulo de Dados finalizado e Resultados da EDA
3 • Dezembro Machine Learning	Modelo 1 (classificação de currículos) e Modelo 2 (valor de cada habilidade com SHAP). As festas de fim de ano servem de folga.	Metodologia (ML) e Resultados de ML
4 • Janeiro Otimização	Ampliar o catálogo de cursos. Conectar os pesos do ML ao otimizador. Análise de sensibilidade. Rodar a matriz de cenários. 2–3 casos de estudantes concretos.	Metodologia (otimização) e Resultados
5 • Fevereiro Visualização e redação	Exportar as tabelas limpas e construir o dashboard. Gráficos finais. Rascunho completo do relatório e primeira versão do pôster.	Relatório v1 completo
6 • Março Fechamento	Semana 1: congelar os resultados (nada de análises novas). Revisão do orientador, apresentação, ensaios. Imprimir o pôster com pelo menos uma semana de antecedência.	Relatório final, apresentação e pôster

MARCOS DE CONTROLE

Reunião com o orientador no fim de cada mês para mostrar o capítulo novo. Assim, as mudanças de rumo aparecem cedo, e não em março.

9 Entregas: relatório, apresentação e pôster

Relatório escrito (aprox. 40–60 páginas)

- 1. **Resumo** (1 página)
- 2. **Introdução:** problema, pergunta de pesquisa e objetivos
- 3. **Revisão de literatura:** lacunas de habilidades, extração de habilidades com NLP, recomendação educacional e otimização combinatória
- 4. **Dados:** fontes, limpeza, taxonomia e qualidade da rotulagem
- 5. **Metodologia:** pipeline, modelos de ML e formulação matemática do otimizador
- 6. **Resultados:** EDA, métricas de ML, otimizador versus baselines e sensibilidade
- 7. **Discussão:** limitações, vieses e ética
- 8. **Conclusões e trabalhos futuros**
- 9. Referências e anexos (o app como demo, dicionário de dados)

Apresentação (aprox. 15–20 minutos, cerca de 15 slides)

Problema → Pergunta → Dados → Pipeline → 1 slide de EDA → 1 para cada modelo de ML → Otimização com um estudante de exemplo ("com C\$ 100 e 30 horas, esta é a trilha") → Resultados versus baselines → Limitações → Conclusão → **demo de 2–3 minutos no app.**

Pôster de congresso (A0 ou 36 × 48 polegadas)

Um pôster precisa ser entendido em 10 segundos a 2 metros de distância: pouco texto, um número grande como protagonista e um diagrama claro do pipeline. Pode ser feito no PowerPoint (ajustando o tamanho da página) ou no Figma.



Esboço da distribuição do pôster

10 Riscos e como lidamos com eles

Risco	Impacto	Plano
As vagas não trazem salário	O Modelo 2 perde sua variável-alvo	Verificar no mês 1. Se faltar, cruzar cada vaga com o salário da Statistics Canada por ocupação, ou prever a <i>demand</i> da habilidade em vez do salário.
Os dados disponíveis são dos EUA e não do Canadá	O foco canadense fica mais fraco	Priorizar o Job Bank Canada. Se usarmos outro dataset, declarar como limitação.
A extração de habilidades comete erros	Lacunas e trilhas incorretas	Amostra rotulada à mão, métricas de precisão e recall e revisão pelo estudante.
Catálogo de cursos pequeno e gratuito	A otimização parece trivial	Ampliar para mais de 100 cursos com preços reais antes de janeiro.
Dados pessoais nos currículos	Problema ético e legal	Anonimizar os .docx. Não usar dados de usuários reais do app sem consentimento. Seção de ética no relatório.
Gastar tempo no app em vez da análise	O projeto perde o foco	App congelado: só mudanças necessárias para a demo.
Power BI não funciona no Mac	Atraso no dashboard	Usar um computador com Windows ou da universidade, ou migrar para Looker Studio ou Tableau Public.

11 Frentes de trabalho e próximos passos

O trabalho se divide naturalmente em quatro frentes. Vamos distribuí-las na reunião de acordo com o interesse e a experiência de cada um.

A · Dados

- Obter e limpar o dataset de vagas
- Taxonomia de habilidades (ESCO)
- Guia de rotulagem e amostra manual
- Ampliar o catálogo de cursos
- Anonimizar os currículos

B · Análise e Machine Learning

- EDA e regressão salarial
- Precisão e recall do extrator
- Modelo 1: classificação de currículos
- Modelo 2: valor de cada habilidade (SHAP)
- Clustering opcional

C · Otimização e avaliação

- Conectar os pesos do ML ao otimizador
- Análise de sensibilidade
- Matriz de cenários versus baselines
- Casos de estudantes para a demo

D · Comunicação

- Revisão de literatura
- Dashboard (Power BI ou alternativa)
- Edição do relatório
- Apresentação e pôster

Próximas duas semanas

1. Apresentar esta proposta ao orientador e validar a abordagem.
2. Baixar os datasets de vagas candidatos e revisar seus campos (principalmente o salário).
3. Escrever o guia de rotulagem e começar a amostra manual.
4. Criar uma pasta compartilhada para notebooks, dados limpos e o rascunho do relatório.

Decisões que tomamos juntos

- Fonte principal de vagas: Job Bank Canada, Kaggle ou uma combinação.
- Mantemos 3 cargos-alvo ou ampliamos?
- Ferramenta de dashboard: Power BI, Looker Studio ou Tableau Public.
- Distribuição das quatro frentes e frequência das reuniões da equipe.