

StudentsCompass como proyecto de Data Analytics

Contexto, lo que ya tenemos, lo que falta y el plan de trabajo para los próximos 6 meses

Análisis de brechas de habilidades y optimización de rutas de aprendizaje para estudiantes internacionales en Canadá, usando datos del mercado laboral, Machine Learning y optimización matemática (OR-Tools).

Contenido

1. Resumen en un minuto
2. El problema que resolvemos
3. La app es la demo, no el proyecto
4. Cómo funciona, paso a paso
5. Lo que ya tenemos
6. Lo que falta
7. El hilo conductor: cómo se conecta todo
8. Plan de 6 meses
9. Entregables: informe, presentación y póster
10. Riesgos y cómo los manejamos
11. Frentes de trabajo y próximos pasos

1 Resumen en un minuto

LA IDEA EN UNA FRASE

Dado el CV de un estudiante, un rol objetivo y un presupuesto limitado de tiempo y dinero, ¿qué cursos debería tomar para quedar lo más preparado posible para el mercado laboral real?

- **Qué es:** nuestro capstone de la maestría en Data Analytics. Combina análisis de datos del mercado laboral, Machine Learning y optimización matemática.
- **Qué es StudentsCompass:** una plataforma web que ya existe y funciona. Para el capstone es **la demo**, el lugar donde se ven los resultados. **No es el proyecto.**
- **El proyecto de verdad** es el motor analítico que va detrás: datos → extracción de habilidades → medición de brechas → modelos de ML → optimización → evaluación con métricas.
- **Ya tenemos** una parte importante: el planteamiento académico, un diccionario de 117 habilidades, la extracción automática de habilidades de CVs, el cálculo de brechas, un optimizador matemático con OR-Tools y su comparación contra 5 métodos simples.
- **Falta** sobre todo: datos reales de vacantes (hoy no tenemos ninguna), el análisis exploratorio y estadístico, los modelos de ML entrenados y evaluados, un catálogo de cursos realista, el dashboard y los tres entregables.
- **Plazo:** 6 meses. **Entregables:** informe escrito, presentación oral y póster de congreso (formato grande). Power BI es un plus, no un requisito.

Cómo cubre el proyecto cada requisito de la maestría

Requisito	Cómo lo cubrimos	Estado
Análisis de datos	Qué habilidades pide el mercado canadiense, por rol, provincia y salario. Regresión de salarios: cuánto "vale" cada habilidad.	Por hacer
Machine Learning	(1) Clasificar CVs por familia profesional. (2) Estimar el valor de mercado de cada habilidad. (Opcional) Agrupar vacantes en perfiles de rol.	Por hacer
Optimización	Modelo matemático (OR-Tools CP-SAT) que elige la mejor ruta de cursos respetando presupuesto, horas y otras restricciones.	Hecho Mejorar
Evaluación	El optimizador se compara contra métodos simples (el curso más barato, el mejor valorado, uno aleatorio...) con las mismas restricciones.	Hecho Con datos reales
Visualización / BI	Dashboard (Power BI si es posible) y figuras para el informe y el póster.	Por hacer

2 El problema que resolvemos

Los estudiantes internacionales que quieren empezar o mejorar su carrera en Canadá tienen una **brecha** entre las habilidades que ya tienen y las que piden las vacantes reales. Hay miles de cursos, certificaciones y recursos, pero no está claro:

- qué habilidades les faltan realmente para el rol que quieren;
- cuáles de esas habilidades importan más en el mercado;
- qué **combinación** de cursos cierra esas brechas mejor, con el tiempo y el dinero que tienen.

El resultado es que muchos estudiantes hacen cursos al azar o aplican a todo sin estrategia.

PREGUNTA DE INVESTIGACIÓN

Dado un CV, un rol objetivo y restricciones reales de tiempo, costo y dificultad, ¿cuál es la ruta óptima de cursos o recursos que maximiza la cobertura de habilidades laborales y mejora la preparación del estudiante?

Objetivo general

Diseñar e implementar un sistema analítico que identifique las brechas de habilidades entre estudiantes internacionales y roles laborales objetivo, y que recomiende rutas de aprendizaje eficientes usando datos del mercado laboral, información del CV, Machine Learning y optimización.

Objetivos específicos

1. Construir una base de datos analítica con habilidades, vacantes, CVs, cursos y sus relaciones.
2. Extraer y normalizar habilidades desde vacantes y CVs, y **medir la precisión** de esa extracción.
3. Analizar la demanda de habilidades en el mercado canadiense (análisis exploratorio y estadístico).
4. Entrenar y evaluar modelos de ML que clasifiquen CVs y estimen el valor de mercado de cada habilidad.
5. Optimizar rutas de aprendizaje bajo restricciones de presupuesto, tiempo, número de cursos y dificultad.
6. Demostrar con métricas que la ruta optimizada supera a métodos simples de selección.

Alcance

Para que el proyecto sea defendible en 6 meses nos concentramos en **3 roles objetivo: Data Analyst, Business Analyst y Junior Data Scientist**. Si da tiempo, se amplía a otros roles al final.

3 La app es la demo, no el proyecto

StudentsCompass es una plataforma web de orientación profesional para estudiantes en Canadá. Guía al estudiante en pasos (autoconocimiento, CV, LinkedIn, búsqueda de empleo...) y tiene una sección llamada **Career Lab**, donde el estudiante sube su CV, elige un rol objetivo y ve sus brechas y una ruta de cursos recomendada. Está construida con FastAPI, PostgreSQL y React, y desplegada en Google Cloud.

La app existe y funciona, pero **no es lo que evalúa el tribunal**. En una maestría de Data Analytics nos evalúan por los datos, los métodos, los resultados y cómo los comunicamos. La app es la vitrina: sirve para enseñar en 2–3 minutos que el sistema funciona con un caso real.

El proyecto (lo que se evalúa)

- Obtención y limpieza de datos del mercado laboral
- Extracción y normalización de habilidades, con precisión medida
- Análisis exploratorio y estadístico
- Modelos de Machine Learning entrenados y evaluados
- Modelo de optimización y su formulación matemática
- Evaluación contra métodos simples
- Dashboard, informe, presentación y póster

La vitrina (la app StudentsCompass)

- Muestra el resultado a un usuario real
- Demo de 2–3 minutos al final de la presentación
- Código QR en el póster para probarla
- Anexo en el informe

LO QUE NO FORMA PARTE DEL CAPSTONE

- La arquitectura de la app, el frontend, el despliegue en la nube y el trabajo de ingeniería de software.
- Las funciones de IA generativa del producto (llamadas a Gemini para analizar CVs o vacantes). **Llamar a un modelo de lenguaje no cuenta como Machine Learning propio**: el tribunal espera modelos que entrenemos, evaluemos y expliquemos nosotros.
- Nuevas funcionalidades de la app. Durante estos 6 meses la app se congela y solo se toca lo necesario para la demo.

4 Cómo funciona, paso a paso

El sistema es una cadena de seis pasos. Cada paso usa el resultado del anterior.

1 Datos Vacantes, CVs y catálogo de cursos	2 Extraer skills Detectar habilidades en el texto	3 Medir la brecha CV frente a rol objetivo	4 Valor (ML) Cuánto vale cada habilidad	5 Optimizar Mejor ruta de cursos	6 Evaluar Contra métodos simples
--	---	--	---	--	--

■ ya existe (hay que alimentarlo con datos reales) ■ nuevo

1 Recoger los datos

Tres fuentes: **vacantes** (qué pide el mercado), **CVs** (qué tienen los estudiantes) y un **catálogo de cursos** con su precio, duración, dificultad y las habilidades que enseñan.

2 Extraer las habilidades

El sistema lee el texto de una vacante o de un CV y detecta qué habilidades aparecen, usando un diccionario de 117 habilidades con sus sinónimos. Por ejemplo, "Python 3" y "python programming" cuentan como la misma habilidad: `python`. El estudiante puede confirmar o rechazar lo detectado.

3 Medir la brecha

Se compara el CV con lo que pide el rol. Cada habilidad que falta recibe un **puntaje de brecha** que combina su importancia para el rol, su demanda en el mercado y cualquier evidencia parcial que ya tenga el estudiante. Así no todas las carencias pesan lo mismo.

4 Estimar el valor de cada habilidad (ML, nuevo)

Un modelo de Machine Learning entrenado con vacantes reales estima cuánto aporta cada habilidad al salario o a la empleabilidad. Hoy esos pesos se fijan a mano con una fórmula; con el ML salen de los datos.

5 Optimizar la ruta de aprendizaje

Un modelo matemático (OR-Tools CP-SAT) elige la combinación de cursos que cierra las brechas **más valiosas** respetando presupuesto, horas disponibles, número máximo de cursos, prerequisites y progresión de dificultad, y evitando cursos redundantes.

6 Evaluar

Con las mismas restricciones, se compara la ruta optimizada contra 5 métodos simples: el curso más barato, el mejor valorado, el más parecido por similitud, la heurística anterior y una selección aleatoria. Se miden 14 métricas: cobertura ponderada, cobertura de habilidades críticas, costo, horas, redundancia, etc.

Ejemplo ilustrativo

CASO SIMPLIFICADO, SOLO PARA ENTENDER LA LÓGICA

Perfil: estudiante internacional en Toronto que quiere ser **Data Analyst**. Tiene 30 horas disponibles y puede hacer como máximo 2 cursos.

Paso 2 — lo que detecta en su CV: Excel y comunicación.

Paso 3 — lo que le falta (importancia en el rol entre paréntesis): SQL (0,95), limpieza de datos (0,90), visualización (0,90), Python (0,80), estadística (0,80), Power BI (0,75) y diseño de KPIs (0,70).

Paso 5 — qué hace el optimizador:

Opción	Horas	Cubre	Resultado
SQL for Data Analysis + Tableau Training	12 + 16 = 28	SQL, limpieza, visualización	Elegida cubre las 3 brechas más valiosas
SQL for Data Analysis + Data Cleaning with Pandas	12 + 8 = 20	SQL, limpieza, Python	Válida, pero Python (0,80) vale menos que visualización (0,90)
SQL for Data Analysis + Power BI Data Analyst	12 + 22 = 34	SQL, limpieza, visualización, Power BI	Descartada supera las 30 horas
Python for Everybody	40	Python	Descartada supera las 30 horas

El optimizador real, además, exige una cobertura mínima por habilidad (0,85 para las críticas y 0,70 para el resto) y penaliza costo, tiempo y redundancia. Por eso el resultado real puede diferir de este ejemplo.

Glosario rápido

Término	Qué significa aquí
Skill gap (brecha)	Habilidad que pide el rol y que el CV no demuestra.
Normalización / taxonomía	Unificar nombres distintos de la misma habilidad bajo un nombre estándar. ESCO es una taxonomía pública europea de habilidades y ocupaciones que podemos usar como referencia.
Embeddings	Representar un texto como un vector numérico para medir parecido semántico ("análisis de datos" se parece a "data analytics"). Usamos el modelo MiniLM guardado en PostgreSQL con pgvector.
OR-Tools / CP-SAT	Librería de Google de investigación de operaciones. CP-SAT es su solver: encuentra la mejor combinación posible dentro de unas restricciones.
Baseline	Método simple de referencia. Si el optimizador no gana a los baselines, no aporta valor.
EDA	Análisis exploratorio de datos: distribuciones, tendencias, correlaciones.
SHAP	Técnica para explicar un modelo de ML: cuánto aporta cada variable (en nuestro caso, cada habilidad) a una predicción.
Precisión / recall	Precisión: de lo que detectamos, cuánto es correcto. Recall: de lo que había, cuánto detectamos.

5 Lo que ya tenemos

El trabajo previo se hizo en fases, documentadas en docs/capstone_product/ y en docs/capstone_phase_1_academic_plan.md dentro del repositorio.

Componente	Estado	Detalle
Planteamiento académico	Hecho	Título, pregunta de investigación, objetivos, alcance, métricas y pipeline conceptual.
Base de datos analítica	Hecho	Tablas de habilidades, sinónimos, habilidades por CV y por vacante, cursos, relación curso-habilidad y ejecuciones del optimizador.
Diccionario de habilidades	Hecho	117 habilidades con sinónimos. 3 roles objetivo con 9–10 habilidades requeridas cada uno y su importancia.
Extracción de habilidades	Hecho	Basada en reglas y en el diccionario. Aplicada a 2.484 CVs: se detectó al menos una habilidad en el 98,4 %. <i>Esto mide cobertura, no precisión: todavía no sabemos cuántas detecciones son correctas.</i>
Revisión por el estudiante	Hecho	El estudiante puede confirmar, rechazar o añadir habilidades antes del análisis.
Puntaje de brecha	Hecho	Ordena las brechas según importancia × demanda del mercado, menos la evidencia parcial.
Optimizador matemático	Hecho	OR-Tools CP-SAT con restricciones de presupuesto, horas, número de cursos, cobertura mínima, dificultad, prerrequisitos y redundancia. Validado con casos sintéticos controlados.
Evaluación contra baselines	Hecho	5 métodos de referencia, 14 métricas y una matriz de 5 escenarios diseñada. Falta correrla con datos reales.
Embeddings semánticos	Parcial	Implementados (MiniLM + pgvector), pero apagados por defecto: hoy se usa un vector de relleno.
App de demo (Career Lab)	Hecho	Funciona en producción: subir CV, elegir rol, ver brechas y ruta.

Datos disponibles hoy

Fuente	Volumen	Comentario
CVs etiquetados (Kaggle Resume Dataset)	2.484	24 categorías profesionales (IT, finanzas, salud, ventas...). Base ideal para el modelo de clasificación.
CVs en Word (.docx)	228	Perfiles de Business Analyst, Project Manager y Java. Tienen nombres reales: hay que anonimizarlos.
CVs en PDF por categoría	~8.900	2,4 GB. Útiles como conjunto extra o de prueba.
Vacantes de empleo	0	El archivo local de vacantes está vacío. Es el bloqueo principal.
Catálogo de cursos	12	Coursera, Kaggle, Microsoft Learn, etc. Todos a costo 0 \$, así que hoy la restricción de presupuesto no filtra nada.

6 Lo que falta

Van en orden de prioridad. Los dos primeros bloquean todo lo demás.

6.1 · DATOS DE VACANTES — BLOQUEANTE

Por qué importa: sin vacantes no hay análisis del mercado laboral, ni ML de valor de habilidades, ni brechas basadas en datos reales.

Cómo: usar datasets públicos en lugar de scraping.

- **Job Bank Canada** (portal de datos abiertos del Gobierno de Canadá, open.canada.ca): vacantes canadienses con ocupación, ubicación y salario. Es la opción que mejor encaja con el enfoque en Canadá.
- **Statistics Canada:** vacantes y salarios por ocupación y provincia. Sirve para completar salarios que falten.
- Alternativa: dataset de Kaggle "LinkedIn Job Postings" (grande y con habilidades y salarios, pero mayormente de EE. UU.).

Primera tarea: descargar y revisar qué campos traen de verdad, sobre todo el salario.

6.2 · MUESTRA ETIQUETADA A MANO — BLOQUEANTE PARA LAS MÉTRICAS

Por qué importa: hoy sabemos en cuántos CVs se detectan habilidades, pero no si están bien detectadas. Sin una referencia manual no podemos reportar precisión ni recall, y el tribunal lo preguntará.

Cómo: etiquetar a mano unas 100 vacantes y 50 CVs (qué habilidades contienen realmente), con una guía de etiquetado común. Si dos personas etiquetan una parte, podemos medir también el acuerdo entre ellas.

6.3 · Análisis exploratorio y estadístico

- Habilidades más demandadas por rol y por provincia.
- Habilidades que aparecen juntas (co-ocurrencia) y cómo agruparlas.
- Distribución de salarios y **regresión salarial:** cuánto sube el salario al tener SQL, Python, Power BI...
- Comparación agregada entre los CVs y el mercado: dónde están las brechas más comunes.

6.4 · Machine Learning

Modelo	Qué hace	Cómo se evalúa
1. Clasificación de CVs	Predice la familia profesional de un CV (24 categorías). Comparamos un modelo clásico (TF-IDF + regresión logística) contra embeddings + clasificador. Usa datos que ya tenemos.	F1 macro, matriz de confusión, validación cruzada.
2. Valor de cada habilidad	Predice el salario (o la demanda) de una vacante a partir de sus habilidades, y con SHAP mide cuánto aporta cada una. Es el modelo que conecta con la optimización.	RMSE/MAE frente a un modelo base; estabilidad de la importancia de cada habilidad.

Modelo	Qué hace	Cómo se evalúa
3. Clustering (opcional)	Agrupar vacantes en perfiles de rol descubiertos a partir de los datos, en vez de definirlos a mano.	Silhouette, interpretación de los grupos.

6.5 · Optimización: mejorar lo que ya existe

- **Conectar el ML con el optimizador.** El modelo matemático ya tiene un parámetro para el valor salarial de cada habilidad, pero hoy vale 0 porque no hay datos. El Modelo 2 lo alimenta.
- **Catálogo de cursos realista:** pasar de 12 cursos gratuitos a más de 100, con precio, horas y dificultad reales (incluyendo certificaciones de pago). Sin esto, el presupuesto no restringe nada.
- **Análisis de sensibilidad:** cómo cambia la cobertura al variar el presupuesto y las horas. La curva resultante es una figura muy potente para el póster.
- **Correr la matriz de escenarios** ya diseñada (poco presupuesto, poco tiempo, equilibrado, otro rol, restricciones duras) con datos reales y reportar las tablas.

6.6 · Visualización y dashboard

Un dashboard de 4 páginas: **Mercado laboral**, **Perfil de los CVs**, **Brechas** (mapa de calor rol × habilidad) y **Optimización** (comparación con los baselines y la curva de sensibilidad).

- **Power BI** es un plus. Ojo: Power BI Desktop solo funciona en Windows. Alternativas que funcionan en Mac: Looker Studio o Tableau Public.
- El dashboard se alimenta de **tablas limpias exportadas** (modelo estrella en CSV o Parquet), nunca de la base de datos de producción de la app.
- Las figuras del informe y del póster se hacen en Python de todas formas.

7 El hilo conductor: cómo se conecta todo

Un error típico en los capstones es presentar tres piezas sueltas: "hicimos un EDA, entrenamos un modelo y además hicimos una optimización". En este proyecto cada pieza alimenta a la siguiente, y esa es la historia que contamos:

Análisis de datos	Machine Learning	Optimización	Evaluación
Qué pide el mercado canadiense y cuánto paga por ello	Convierte esa evidencia en un valor numérico por habilidad	Elige los cursos que maximizan ese valor con el tiempo y dinero disponibles	Demuestra que gana a los métodos simples

LA FRASE PARA EL TRIBUNAL

"El análisis de datos nos dice qué pide el mercado; el Machine Learning nos dice cuánto vale cada habilidad; la optimización decide qué debe estudiar cada estudiante para ganar el máximo valor con su tiempo y su dinero; y la evaluación demuestra que funciona mejor que las alternativas simples."

8 Plan de 6 meses

Regla principal: cada mes termina con un análisis hecho y el borrador del capítulo correspondiente del informe. En el último mes solo se pule; no se empieza a escribir.

Mes	Trabajo	Resultado para el informe
1 • Octubre Datos y alcance	Validar la propuesta con el tutor. Conseguir y revisar el dataset de vacantes. Elegir la taxonomía (ESCO). Definir la guía de etiquetado y etiquetar la muestra manual. Empezar la revisión de literatura.	Borradores de Introducción y Datos
2 • Noviembre Análisis de datos	Limpiar y normalizar las habilidades. Medir la precisión y el recall del extractor contra la muestra. EDA completo y regresión salarial.	Capítulo de Datos terminado y Resultados del EDA
3 • Diciembre Machine Learning	Modelo 1 (clasificación de CVs) y Modelo 2 (valor de cada habilidad con SHAP). Las fiestas sirven de colchón.	Metodología (ML) y Resultados de ML
4 • Enero Optimización	Ampliar el catálogo de cursos. Conectar los pesos del ML al optimizador. Análisis de sensibilidad. Correr la matriz de escenarios. 2–3 casos de estudiantes concretos.	Metodología (optimización) y Resultados
5 • Febrero Visualización y redacción	Exportar las tablas limpias y construir el dashboard. Figuras finales. Borrador completo del informe y primer borrador del póster.	Informe v1 completo
6 • Marzo Cierre	Semana 1: congelar resultados (no más análisis nuevos). Revisión del tutor, presentación, ensayos. Imprimir el póster con al menos una semana de antelación.	Informe final, presentación y póster

HITOS DE CONTROL

Reunión con el tutor al final de cada mes para enseñarle el capítulo nuevo. Así los cambios de rumbo llegan pronto y no en marzo.

9 Entregables: informe, presentación y póster

Informe escrito (aprox. 40–60 páginas)

1. **Resumen** (1 página)
2. **Introducción:** problema, pregunta de investigación y objetivos
3. **Revisión de literatura:** brechas de habilidades, extracción de habilidades con NLP, recomendación educativa y optimización combinatoria
4. **Datos:** fuentes, limpieza, taxonomía y calidad del etiquetado
5. **Metodología:** pipeline, modelos de ML y formulación matemática del optimizador
6. **Resultados:** EDA, métricas de ML, optimizador frente a baselines y sensibilidad
7. **Discusión:** limitaciones, sesgos y ética
8. **Conclusiones y trabajo futuro**
9. Referencias y anexos (la app como demo, diccionario de datos)

Presentación (aprox. 15–20 minutos, unas 15 diapositivas)

Problema → Pregunta → Datos → Pipeline → 1 diapositiva de EDA → 1 por cada modelo de ML → Optimización con un estudiante de ejemplo ("con 100 \$ y 30 horas, esta es su ruta") → Resultados frente a baselines → Limitaciones → Conclusión → **demo de 2–3 minutos en la app.**

Póster de congreso (A0 o 36 × 48 pulgadas)

Un póster se tiene que entender en 10 segundos a 2 metros: poco texto, un número grande como protagonista y un diagrama claro del pipeline. Se puede diseñar en PowerPoint (ajustando el tamaño de página) o en Figma.



Boceto de distribución del póster

10 Riesgos y cómo los manejamos

Riesgo	Impacto	Plan
Las vacantes no traen salario	El Modelo 2 pierde su variable objetivo	Revisarlo en el mes 1. Si falta, unir cada vacante con el salario de Statistics Canada por ocupación, o predecir la <i>demand</i> de la habilidad en lugar del salario.
Los datos disponibles son de EE. UU. y no de Canadá	Se debilita el enfoque canadiense	Priorizar Job Bank Canada. Si se usa otro dataset, declararlo como limitación.
La extracción de habilidades comete errores	Brechas y rutas incorrectas	Muestra etiquetada a mano, métricas de precisión y recall, y revisión por parte del estudiante.
Catálogo de cursos pequeño y gratuito	La optimización parece trivial	Ampliarlo a más de 100 cursos con precios reales antes de enero.
Datos personales en los CVs	Problema ético y legal	Anonimizar los .docx. No usar datos de usuarios reales de la app sin consentimiento. Sección de ética en el informe.
Dedicar tiempo a la app en lugar de al análisis	El proyecto pierde foco	App congelada: solo cambios necesarios para la demo.
Power BI no funciona en Mac	Retraso en el dashboard	Usar un equipo con Windows o de la universidad, o pasar a Looker Studio o Tableau Public.

11 Frentes de trabajo y próximos pasos

El trabajo se divide naturalmente en cuatro frentes. Los repartimos en la reunión según el interés y la experiencia de cada uno.

A · Datos

- Conseguir y limpiar el dataset de vacantes
- Taxonomía de habilidades (ESCO)
- Guía de etiquetado y muestra manual
- Ampliar el catálogo de cursos
- Anonimizar los CVs

B · Análisis y Machine Learning

- EDA y regresión salarial
- Precisión y recall del extractor
- Modelo 1: clasificación de CVs
- Modelo 2: valor de cada habilidad (SHAP)
- Clustering opcional

C · Optimización y evaluación

- Conectar los pesos del ML al optimizador
- Análisis de sensibilidad
- Matriz de escenarios frente a baselines
- Casos de estudiantes para la demo

D · Comunicación

- Revisión de literatura
- Dashboard (Power BI o alternativa)
- Edición del informe
- Presentación y póster

Próximas dos semanas

1. Presentar esta propuesta al tutor y validar el enfoque.
2. Descargar los datasets de vacantes candidatos y revisar sus campos (sobre todo el salario).
3. Redactar la guía de etiquetado y empezar la muestra manual.
4. Crear una carpeta compartida para notebooks, datos limpios y el borrador del informe.

Decisiones que tomamos juntos

- Fuente principal de vacantes: Job Bank Canada, Kaggle o una combinación.
- ¿Mantenemos 3 roles objetivo o ampliamos?
- Herramienta de dashboard: Power BI, Looker Studio o Tableau Public.
- Reparto de los cuatro frentes y frecuencia de reuniones del equipo.